

Машинное обучение (часть 1)

Лекция 4. Логистическая регрессия

Заливако Сергей Сергеевич

Кафедра Информатики (402-5)
zalivako@bsuir.by



Примеры задач

- Определение спама в электронных письмах;
- Определение, является ли транзакция мошеннической;
- Определение злокачественности опухолей.


Бинарная классификация $y \in \{0, 1\}$

- 0 – “отрицательный” класс (например, опухоль является доброкачественной);
- 1 – “положительный” класс (например, опухоль является злокачественной);


Многоклассовая классификация $y \in \{0, 1, 2, 3\}$

- 0 – объект на картинке является пешеходом;
- 1 – объект на картинке является дорожным знаком;
- 2 – объект на картинке является автомобилем;
- 3 – объект на картинке не опознан;

Задача определение злокачественности опухоли




Задача определение злокачественности опухоли




Как решить с помощью линейной регрессии?

Решение с помощью линейной регрессии




Решение с помощью линейной регрессии



Если $h_{\theta}(x) \geq 0.5$, то $y = 1$,

Если $h_{\theta}(x) < 0.5$, то $y = 0$.

Решение с помощью линейной регрессии




Если $h_{\theta}(x) \geq 0.5$, то $y = 1$,


Если $h_{\theta}(x) < 0.5$, то $y = 0$.

Проблема в том, что $h_{\theta}(x)$ может принимать значения < 0 и > 1 .

Логистическая функция (сигмоид)



Логистическая функция (сигмоид)



$$f(z) = \frac{1}{1+e^{-z}}$$

$$h_{\theta}(x) = g(\theta^T x)$$

$$g(z) = \frac{1}{1+e^{-z}}$$

$$y = 1, \text{ если } h_{\theta}(x) \geq 0.5$$

Интерпретация логистической функции

$$h_{\theta}(x) = g(\theta^T x)$$
$$g(z) = \frac{1}{1+e^{-z}}$$

$y = 1$, если $h_{\theta}(x) \geq 0.5$
Следовательно $\theta^T x \geq 0$.


$y = 0$, если $h_{\theta}(x) < 0.5$
Следовательно $\theta^T x < 0$.

Значение $0 \leq h_{\theta}(x) \leq 1$.


Таким образом, $h_{\theta}(x)$ оценивает **вероятность** того, что объект x принадлежит “положительному” классу ($y = 1$).

Другими словами, $h_{\theta}(x) = P(y = 1|x; \theta);$
 $P(y = 0|x; \theta) + P(y = 1|x; \theta) = 1$

Разделяющая поверхность




Разделяющая поверхность




Уравнение данной поверхности – $\theta^T x$

Разделяющая поверхность




Уравнение данной поверхности – $\theta^T x$
 $y = 1$, если $x_1 + x_2 \geq 3$.

Нелинейная разделяющая поверхность



Нелинейная разделяющая поверхность



Уравнение данной поверхности – $x_1^2 + x_2^2 \geq 1$.

Обучающая выборка

$$\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\}$$

$$x = \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_n \end{bmatrix} \in \mathbb{R}^{n+1}, y \in \{0, 1\}$$

Гипотеза $h_{\theta}(x) = \frac{1}{1+e^{-\theta^T x}}$

Обучающая выборка

$$\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})\}$$

$$x = \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_n \end{bmatrix} \in \mathbb{R}^{n+1}, y \in \{0, 1\}$$

Гипотеза $h_{\theta}(x) = \frac{1}{1+e^{-\theta^T x}}$


Как выбрать параметры θ ?

Квадратичная функция стоимости

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Квадратичная функция стоимости

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$



Функция стоимости для логистической регрессии


$$\text{Cost}(h_{\theta}(x), y) = -\log(h_{\theta}(x)), \text{ если } y = 1$$

$$\text{Cost}(h_{\theta}(x), y) = -\log(1 - h_{\theta}(x)), \text{ если } y = 0$$

Функция стоимости для логистической регрессии

$Cost(h_{\theta}(x), y) = -\log(h_{\theta}(x))$, если $y = 1$

$Cost(h_{\theta}(x), y) = -\log(1 - h_{\theta}(x))$, если $y = 0$



Объединение двух частей функции потерь

$$\text{Cost}(h_{\theta}(x), y) = -\log(h_{\theta}(x)), \text{ если } y = 1$$

$$\text{Cost}(h_{\theta}(x), y) = -\log(1 - h_{\theta}(x)), \text{ если } y = 0$$

Объединение двух частей функции потерь

$$\text{Cost}(h_{\theta}(x), y) = -\log(h_{\theta}(x)), \text{ если } y = 1$$

$$\text{Cost}(h_{\theta}(x), y) = -\log(1 - h_{\theta}(x)), \text{ если } y = 0$$

Функция потерь $J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$

Объединение двух частей функции потерь

$$\text{Cost}(h_{\theta}(x), y) = -\log(h_{\theta}(x)), \text{ если } y = 1$$

$$\text{Cost}(h_{\theta}(x), y) = -\log(1 - h_{\theta}(x)), \text{ если } y = 0$$

Функция потерь $J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$$

Объединение двух частей функции потерь

$$\text{Cost}(h_{\theta}(x), y) = -\log(h_{\theta}(x)), \text{ если } y = 1$$

$$\text{Cost}(h_{\theta}(x), y) = -\log(1 - h_{\theta}(x)), \text{ если } y = 0$$

Функция потерь $J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$$

Оптимизация $\underset{\theta}{\text{minimize}} J(\theta)$

Объединение двух частей функции потерь

$$\text{Cost}(h_{\theta}(x), y) = -\log(h_{\theta}(x)), \text{ если } y = 1$$

$$\text{Cost}(h_{\theta}(x), y) = -\log(1 - h_{\theta}(x)), \text{ если } y = 0$$

Функция потерь $J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$$

Оптимизация $\underset{\theta}{\text{minimize}} J(\theta)$

Прогноз $h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$

Градиентный спуск для логистической регрессии

Пока не достигнута сходимость {
 $\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$
}

Градиентный спуск для логистической регрессии

Пока не достигнута сходимость {
 $\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$
}

$$j = 0, 1, \dots, n$$

Пока не достигнута сходимость {
 $\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$
}

$$j = 0, 1, \dots, n$$

Формулы для обновления параметров

$$\theta_0 = \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$\theta_1 = \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^{(i)}$$

...

$$\theta_n = \theta_n - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_n^{(i)}$$

Пока не достигнута сходимость {
 $\theta_j = \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$
}

$$j = 0, 1, \dots, n$$

Формулы для обновления параметров

$$\theta_0 = \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$\theta_1 = \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^{(i)}$$

...

$$\theta_n = \theta_n - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_n^{(i)}$$

Алгоритм такой же, как и для линейной регрессии!

Применение более сложных методов оптимизации

Пусть дан вектор параметров θ , тогда необходимо определить:

- Процедуру вычисления $J(\theta)$;
- Процедуру вычисления $\frac{\partial}{\partial \theta_j} J(\theta) \forall j \in \{1, 2, \dots, n\}$;

Пусть дан вектор параметров θ , тогда необходимо определить:

- Процедуру вычисления $J(\theta)$;
- Процедуру вычисления $\frac{\partial}{\partial \theta_j} J(\theta) \forall j \in \{1, 2, \dots, n\}$;

Тогда можно использовать такие методы как:

- BFGS;
- L-BFGS;
- Нелдер-Мид;
- Генетические методы;
- ...

Пусть дан вектор параметров θ , тогда необходимо определить:

- Процедуру вычисления $J(\theta)$;
- Процедуру вычисления $\frac{\partial}{\partial \theta_j} J(\theta) \forall j \in \{1, 2, \dots, n\}$;

Тогда можно использовать такие методы как:

- BFGS;
- L-BFGS;
- Нелдер-Мид;
- Генетические методы;
- ...

Преимущества:

- Нет необходимости настраивать α ;
- Обычно большая производительность, чем при градиентном спуске.

Недостатки:

- Более сложны в реализации.

Распределение писем по папкам $y \in \{0, 1, 2, 3\}$

- 0 – работа;
- 1 – друзья;
- 2 – семья;
- 3 – хобби.


Медицинский диагноз $y \in \{0, 1, 2\}$

- 0 – здоров;
- 1 – простуда;
- 2 – грипп.

Предсказание погоды $y \in \{0, 1, 2, 3\}$

- 0 – солнечно;
- 1 – облачно;
- 2 – дождь;
- 3 – снег;

One-vs-all (one-vs-rest)






$$\lim_{x \rightarrow 8} \frac{1}{x-8} = \infty$$

$$\lim_{x \rightarrow 5} \frac{1}{x-5} =$$


$$\lim_{x \rightarrow 8} \frac{1}{x-8} = \infty$$

$$\lim_{x \rightarrow 5} \frac{1}{x-5} = \infty$$

Переобученная линейная регрессия



Переобученная логистическая регрессия



Функция стоимости

$$J(\theta) = \frac{1}{2m} [\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2]$$

Функция стоимости

$$J(\theta) = \frac{1}{2m} [\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2]$$

Градиентный спуск

$$\theta_0 = \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$\theta_1 = \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^{(i)} + \frac{\lambda}{m} \theta_1$$

...

$$\theta_n = \theta_n - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_n^{(i)} + \frac{\lambda}{m} \theta_n$$

Функция стоимости

$$J(\theta) = \frac{1}{2m} [\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2]$$

Градиентный спуск

$$\theta_0 = \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$\theta_1 = \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^{(i)} + \frac{\lambda}{m} \theta_1$$

...

$$\theta_n = \theta_n - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_n^{(i)} + \frac{\lambda}{m} \theta_n$$

Аналитическое решение

$$\theta = (X^T X + \lambda \begin{bmatrix} 0 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix})^{-1} X^T y$$

Функция стоимости $J(\theta) =$

$$-\frac{1}{m}[\sum_{i=1}^m [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1-y^{(i)}) \log(1-h_{\theta}(x^{(i)}))]] + \lambda \sum_{j=1}^n \theta_j^2]$$

Функция стоимости $J(\theta) =$

$$-\frac{1}{m}[\sum_{i=1}^m [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1-y^{(i)}) \log(1-h_{\theta}(x^{(i)}))]] + \lambda \sum_{j=1}^n \theta_j^2]$$

Градиентный спуск

$$\theta_0 = \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$\theta_1 = \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_1^{(i)} + \frac{\lambda}{m} \theta_j$$

...

$$\theta_n = \theta_n - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_n^{(i)} + \frac{\lambda}{m} \theta_j$$